상충 및 불충분한 상품정보 환경에서 근거 기반 쇼핑 질의응답을 위한 신뢰성 인지RAG

Trust-Aware RAG for Evidence-Grounded Shopping Question Answering under Conflicting and Insufficient Product Information

Chae-Eun Kim, Yu-Jin Chung, Tae-Wan Kim
Dept of Data Science, Dongduk Women's University
{chaeeun0023, minteugene59}@gmail.com, kimtwan21@dongduk.ac.kr

ABSTRACT

온라인 쇼핑에서는 판매자의 상품설명과 구매자 리뷰가 서로 상충하거나 근거 자체가 불충분한 경우가 적지 않다. 본 연구는 두 출처 간 근거 상태를 일관·상충·불충분으로 정의하고, 상태에 따라 직접 답변·양측 병기·답변 보류를 선택하는 신뢰성 인지 RAG(Trust-Aware RAG)를 제안한다. Amazon Reviews 2023과 AmazonQA 기반 Electronics·Office Products 600건 평가셋으로 LLM 단독·기본 RAG·출처 구분 RAG와 비교한 결과, 실제 분류기 기반 제안 모델은 출처 구분 RAG를 상회하지 못했으나, 정확한 근거 상태를 사용한 Oracle 분석을 통해 상태 조건부 생성의 잠재 효과와 근거 상태 분류 정확도의 중요성을 확인하였다.

INTRODUCTION

온라인 쇼핑에서 소비자는 상품을 직접 확인할 수 없어 판매자의 상품설명에 의존하지만, 실제 구매자의 리뷰는 종종 이와 다른 정보를 제공한다. 기존 RAG 기반 질의응답 시스템은 검색된 자료들 사이의 이러한 상충이나 근거 부족을 구분하지 않고 하나의 답변으로 뭉뚱그려, 근거 없는 단정이나 한쪽에 치우친 답변을 생성하는 문제가 있다.

본 연구는 판매자 상품설명과 구매자 리뷰 사이의 관계를 일관(지지)·상충(반박)·불충분(근거 없음) 세 가지 상태로 명시적으로 판정하고, 그 상태에 맞는 방식으로 답변을 생성하는 신뢰성 인지 RAG를 제안한다.

PROPOSED METHOD

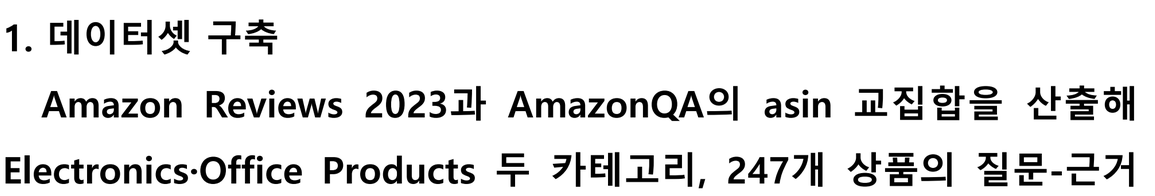
1. 데이터셋 구축

Amazon Reviews 2023과 AmazonQA의 asin 교집합을 산출해 Electronics·Office Products 두 카테고리, 247개 상품의 질문-근거 후보 2,295건을 구성했다. 카테고리 비율 70:30, 근거 상태 비율(상충 35%·일관 35%·불충분 30%)로 층화추출해 600건을 최종 선정했으며, 상품당 최대 5건으로 제한해 특정 상품의 과대표집을 방지했다.

2. 근거 상태 판정 로직

지지 리뷰만 있으면 일관, 반박 리뷰가 1건 이상이면 상충, 관련 근거가 없으면 불충분으로 판정한다. 상충은 반박 리뷰 수에 따라 약함(1–2건)·중간(3–4건)·강함(5건 이상)으로 세분화한다. 숫자나 단위가 같아도 속성이 다르면 상충으로 보지 않도록 주의했다.

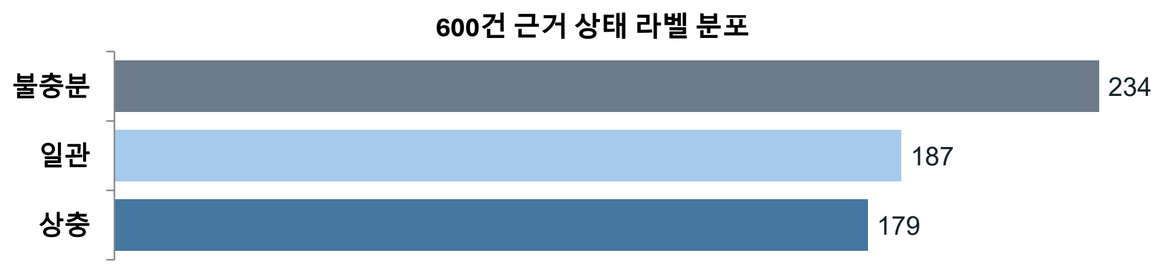
3. 신뢰성 인지 RAG 파이프라인



DATASET & LABELING RESULTS

최종 선정 600건의 근거 상태 라벨 분포는 불충분 234건(39%), 일관 187건(31%), 상충 179건(30%)이다. 층화추출은 규칙 기반 근거 상태 추정값을 기준으로 상충 35%·일관 35%·불충분 30%로 수행되었으나, 이후 실제 라벨링 과정에서 상태가 재판정되며 위와 같은 분포로 확정되었다.

이 데이터셋으로 DeBERTa 기반 근거 상태 분류기를 학습·튜닝(A/B/C)한 결과, 최종 분류기는 Test Macro-F1 0.4696(Recall: 일관 0.629 · 상충 0.433 · 불충분 0.353)을 기록해, 상충·불충분 판별이 상대적으로 어려운 과제임을 확인했다.



EXPERIMENTAL RESULTS

AI-judge 예비 평가(사람 평가 추후 진행)에서 출처 구분 RAG(B2)는 State Handling·Usefulness·Overclaim에서 가장 우수했다. 제안 모델(P1)은 B0·B1보다 낮은 Overclaim을 보여 근거 없는 단정을 줄이는 효과는 확인했으나, B2는 상회하지 못했다.

비교군	Groundedness	State Handling	Usefulness	Overclaim	3지표 평균
B0. LLM 단독	2.64	3.19	3.20	23.2%	3.01
B1. 기본 RAG	3.82	4.03	4.11	16.2%	3.99
B2. 출처 구분 RAG	3.57	4.39	4.20	6.1%	4.05
P1. 신뢰성 인지 RAG	3.67	4.08	4.11	13.1%	3.95

Oracle 분석 (Upper Bound) — Gold Trust-aware RAG

전체 Test 기준 Gold Trust-aware RAG의 3지표 평균은 4.32로 비교 방법 중 가장 높았다. classifier가 상태를 정확히 맞힌 사례에서 제안 모델은 4.40으로 Gold(4.43)에 근접했으나, 오답 사례에서는 3.55로 감소해, 상태 분류 정확도가 현재 시스템의 주요 성능 병목임을 확인하였다.

CONCLUSION

본 연구는 판매자-리뷰 간 근거 상태를 판정하고, 상태에 따라 응답 전략을 조절하는 신뢰성 인지 RAG를 제안하였다. 600건 데이터셋 구축과 DeBERTa 분류기 학습을 거쳐 4개 비교군 실험을 수행하였다. AI-judge 예비 평가에서 제안 모델은 출처 구분 RAG를 전체적으로 상회하지 못했으나, Gold state 사용 및 classifier 정답 사례에서는 성능이 크게 향상되었다. 이는 상태 조건부 생성의 가능성과 함께 근거 상태 분류 정확도가 현재 시스템의 주요 병목임을 보여준다. 향후 classifier 개선과 사람 평가를 통해 이를 검증한다.